



UNIVERSIDAD DE BUENOS AIRES FACULTAD DE CIENCIAS EXACTAS Y
NATURALES

DATOS, ECUACIONES DIFERENCIALES E INTELIGENCIA ARTIFICIAL

Aproximación diferencial a la dinámica de contagio de SARS-CoV-2 en EE.UU. con UDE

Santiago Gesualdi

Carolina Zappala

(santii.i@uba.ar)

(caro.zappala@gmail.com)

Instructor: Facundo Sapienza

Resumen

El modelado de una epidemia tal como lo fue el virus SARS-CoV-2 resulta de gran interés teniendo en cuenta las distintas lecturas posibles de sus efectos. Para ello, se postula un modelo SEIRVD con retardo aplicando redes neuronales, en particular el enfoque UDE, para parametrizar esta dinámica e inferir nociones de comportamiento poblacional ante estas situaciones. El modelo propuesto en el presente trabajo resulta de ayuda a dicho fin y consigue explicar, en general, la dinámica del sistema.

Palabras clave: redes neuronales, UDE, SEIRVD, optimización.

24 de junio de 2026

1. Introducción

En epidemiología, los procesos de dispersión y propagación de enfermedades infecciosas, tales como el SARS-CoV-2, permiten ser modelados mediante enfoques matemáticos que establecen relaciones dinámicas entre los agentes sociales del proceso infecciosos y construyen un alto nivel de conocimiento sobre estos mecanismos.¹ Estas aproximaciones se sustentan sobre modelos compartimentales diferenciales que toman, por regla general, el enfoque **SIR** (susceptibles, infectados y recuperados),^{2,3} donde se vinculan las variaciones entre estos grupos afectados, y pueden expandirse a fin de incluir información clave de la dinámica de la enfermedad; ya sea en materia patógena, inmunológica, o social, como puede ser, la inclusión de tiempos de incubación del virus dentro del organismo; dando paso a modelos **SEIR**,⁴ donde *E* referencia al grupo poblacional de expuestos al virus (personas que contrajeron el virus pero no contagian al resto). Este tipo de modelos permiten un mejor acercamiento a la dinámica de contagio de esta enfermedad, y promueve una interpretación más acertada del mismo con el fin de amortiguar sus efectos. Para mejorar la representación de ciertos esquemas epidemiológicos más complejos, se extiende al modelo **SEIRVD**, que integra vacunados y fallecidos acumulados.

Se puede recurrir a distintas estrategias conocidas para resolver la dinámica de un problema físico combinándola con herramientas de *machine learning*. Las **PINNs** (Redes Neuronales Informadas por la Física) integran el término físico como una penalización en la función de pérdida que se busca minimizar en el modelado del problema.⁵ Esto se traduce en una restricción suave en la misma, en contraposición con las **NODEs** (Ecuaciones Diferenciales Ordinarias Neuronales) y **UDEs** (Ecuaciones Diferenciales Universales), las cuales integran a la física en el modelo de forma tal que imponga una restricción fuerte que la red debe cumplir numéricamente. Las **NODEs** son útiles para trabajar cuando no se conoce la matemática que rige el problema que se quiere aproximar, ya que las redes neuronales reemplazan la totalidad de la función que determina el ecosistema a modelar. En cambio, las **UDEs** permiten mantener la estructura ya conocida del sistema de ecuaciones con el que se parte, al mismo tiempo que un aproximador universal hace su trabajo para alcanzar los parámetros buscados; en efecto, una red neuronal puede actuar como aproximador universal.⁵

El COVID-19 significó una amenaza sanitaria de crecimiento particularmente veloz, que fue abordada de diferentes maneras en todo el mundo. El virus dio comienzo en diciembre del 2019 en la ciudad de Wuhan, China, y rápidamente fue declarado “Emergencia de Salud Pública Internacional” por la OMS, definiéndola oficialmente como pandemia el 30 de enero de 2020.⁶ En particular, consideramos el caso de Estados Unidos donde las políticas interestatales fueron descentralizadas, lo que produjo respuestas variadas con respecto al impacto social y económico, sectores que se vieron amenazados por el COVID a lo largo del país.⁷

Para el modelado epidemiológico de este caso, es oportuno integrar el tiempo de respuesta, producto del período de incubación del virus, a modo de retardo temporal en las ecuaciones que rigen la dinámica del contagio. Así, se da lugar a las **DDEs** (Ecuaciones Diferenciales con Retardo).⁸ Las mismas permiten que la tasa de cambio de la población infectada en un instante dependa del estado del sistema en un tiempo previo, incorporando la

historia del mismo en términos de contagio.

El objetivo de este trabajo es, a partir del modelado de un sistema diferencial mediante el uso de UDE, caracterizar la dinámica de contagio del Sars-CoV-2 a través de parámetros entrenables para permitir futuros análisis de eficiencia e impacto de medidas sanitarias, políticas y sociales durante la pandemia. Este enfoque es útil, por un lado, para validar el uso de redes neuronales a la hora de aproximar los parámetros del modelo, lo que ayuda a la predicción evolutiva del virus en el tiempo y sus efectos sociales; y por otro lado, para permitir discusiones futuras a cerca de la eficacia de las distintas estrategias y medidas tomadas a lo largo de la pandemia, facilitando la toma de decisiones en un contexto determinante y urgente.

2. Métodos

El modelo de ecuaciones diferenciales seguido es una modificación directa del presentado por⁹ que, a su vez, resulta de una intervención del **SEIRVD**. En este caso, se hace uso de las variables vistas en el cuadro 1.

Símbolo	Definición	Condición inicial
Variables de Estado (Poblaciones)		
S	Proporción de población susceptible	$1,0 - E_0 - I_0 - D_0$
E	Proporción de población expuesta (en periodo de incubación)	C_0
I	Proporción de población infectada sintomática	C_0
R	Proporción recuperada (con inmunidad temporal)	$0,0$
V	Proporción de población vacunada (inmunidad efectiva)	$0,0$
D	Proporción de muertes acumuladas por la enfermedad	D_0
C	Proporción casos confirmados acumulados	C_0
V_{acc}	Proporción vacunados acumulados	$0,0$

Cuadro 1: Definición de variables utilizados en el modelo (UDE) junto con la condición inicial utilizada donde X_0 indica la proporción obtenida de los datos de entrenamiento para la variable X .

Por simplicidad, se define, a su vez, la siguiente relación entre variables $\rho = S \cdot (\beta_i I + \beta_e E)$ y $\rho_\tau = S_\tau \cdot (\beta_i^\tau I_\tau + \beta_e^\tau E_\tau)$, en donde τ indica que se está aplicando sobre las indicadas un retardo temporal dado por $T(\tau) = 6 \cdot \sigma(0,1 \tau) + 3$ con $\sigma(x) = \left(\frac{1}{1+e^{-x}}\right)$; se utiliza el retardo $T(\tau)$ expresado de esta manera por motivos

explicados en sección 4. A partir de todo lo anterior, es posible establecer el sistema de ecuaciones correspondiente a

$$\left\{ \begin{array}{l} \frac{dS}{dt} = -\rho - vS + \omega R + \eta V \\ \frac{dE}{dt} = \rho - \rho_\tau \\ \frac{dI}{dt} = (1 - \phi_E)\rho_\tau - (\phi_R + \phi_D)I \\ \frac{dR}{dt} = \phi_E\rho_\tau + \phi_R I - \omega R \\ \frac{dV}{dt} = vS - \eta V \\ \frac{dD}{dt} = \phi_D I \\ \frac{dC}{dt} = (1 - \phi_E)\rho_\tau \\ \frac{dV_{acc}}{dt} = vS \end{array} \right. \quad (1)$$

haciendo uso de los parámetros constantes o con dependencia temporal definidos e indicados en el cuadro 2.

Símbolo	Definición	Tipo / Origen	Condición inicial
Parámetros Físicos Constantes			
T	Tiempo de retardo o periodo de incubación	Optimizado (Mecánico)	6.0
ω	Tasa de pérdida de inmunidad natural ($R \rightarrow S$)	Optimizado (Mecánico)	0.1
η	Tasa de pérdida de eficacia de la vacuna ($V \rightarrow S$)	Optimizado (Mecánico)	0.0015
Parámetros Variables en el Tiempo			
$\beta_i(t)$	Tasa de contagio por infectados sintomáticos	Red Neuronal (UDE)	-
$\beta_e(t)$	Tasa de contagio por expuestos/asintomáticos	Red Neuronal (UDE)	-
$\phi_e(t)$	Proporción de individuos asintomáticos al incubar	Red Neuronal (UDE)	-
$\phi_r(t)$	Tasa de recuperación de la enfermedad	Red Neuronal (UDE)	-
$\phi_d(t)$	Tasa de mortalidad inducida por el virus	Red Neuronal (UDE)	-
$v(t)$	Tasa de vacunación administrada a susceptibles	Red Neuronal (UDE)	-

Cuadro 2: Definición de parámetros utilizados en el sistema de ecuaciones diferenciales y optimizados por el modelo de código, indicando aquellos devueltos por la red neuronal y aquellos constantes dados por el solucionador junto con la condición inicial aplicada sobre ellos, donde - indica que depende de la configuración de la red.

Para el trabajo con las ecuaciones mencionadas se ejecutó el proceso descrito en la figura 1 donde, en primera instancia, se muestra la aplicación de *Fourier Features* para, a través de la multiplicación del tiempo t por un espectro de 4 frecuencias dado por (0,5; 1,0; 2,0; 4,0), facilitar el aprendizaje de altas frecuencias.¹⁰ Luego, se utilizaron tanto la descomposición como la variable temporal como entradas de la red neuronal entrenada, la cual consta de 3 capas ocultas, todas ellas con función de activación *Swish* $f(x) = x \cdot \sigma(\beta x)$ con β entrenable. Estas poseen hasta 64 neuronas y retorna 9 valores que, a su vez, son normalizados de la forma $L_i \cdot \sigma(x_i) + \epsilon$ donde x_i es el valor i -ésimo devuelto por la red neuronal, L_i una cota máxima preestablecida para cada parámetro representado y $\epsilon = 1 \times 10^{-12}$ un termino de regularización para evitar valores nulos y soluciones triviales (que se vio, durante fases del desarrollo, que son las más sencillas de aprender para la red).

El proceso de trabajo comenzó con la limpieza de los datos presentes en la base utilizada y una discriminación inicial de Estados en función de la cantidad de reportes de infectados y muertes acumuladas en los mismos, tomando a California como el elegido con el cual trabajar por ser el que mayor cantidad de informes presentó en el período de análisis comprendido entre el 12 de abril de 2020 hasta el 08 de marzo de 2023. Se utilizaron los datos de casos tanto acumulados como nuevos en el período a fin de poder modelar mejor las regiones de alta varianza donde se presentan olas nuevas de contagiados. Por motivos explícitos en sección 4, se vio la necesidad de utilizar reportes de vacunación. Se tomó exclusivamente la aplicación de la primera dosis en la población, sin discriminar por laboratorio, origen ni propiedades similares de la misma. Para definir lo que llamaremos períodos de trabajo, se realizó un análisis sobre la base de datos registrando cuándo se agregaban nuevos valores de infectados o vacunados en ella; los valores negativos, que, por indicaciones de la fuente, identifican una corrección a datos anteriores, fueron directamente restados al período anterior, lo cual, a pesar de poder generar ruido o perturbaciones en caso de que la corrección particular sea sobre un tiempo más distante, simplifica la construcción del conjunto de datos de interés. Se remarca que los períodos de vacunación e infección (y muertes) no son necesariamente idénticos por lo que se realizaron dos conteos independientes.




Figura 1: Representación de la estructura utilizada a partir de la discretización temporal.

Se indica que el modelo busca aproximar las variables normalizadas, es decir, la distribución de cada una de las poblaciones predichas dada la totalidad de individuos en el Estado analizado a partir de estimaciones para el año 2020.¹¹

Para aproximar estos datos y calibrar los parámetros del sistema de ecuaciones, se buscó optimizar la función de costo total

$$\mathcal{L}_{total}(\theta) = \mathcal{L}_C + w_D \mathcal{L}_D + w_V \mathcal{L}_V + w_{dC} \mathcal{L}_{dC} + w_S \mathcal{L}_{suave} + \lambda \|\theta_{NN}\|_2^2 \quad (2)$$

donde w_D , w_V Y w_{dC} ponderan las pérdidas por muertes, vacunación y casos nuevos, λ es la regularización $L2$ sobre los pesos, y w_S controla la penalización de suavidad. Los errores poblacionales ($\mathcal{L}_C$, $\mathcal{L}_D$, $\mathcal{L}_V$) se calcularon mediante *Log-MSE*

$$\mathcal{L}_X = \frac{1}{N} \sum_{i=1}^N \left(\log(\sqrt{\hat{X}_i^2 + \delta} + \epsilon) - \log(X_i + \epsilon) \right)^2 \quad (3)$$

donde X_i es el dato empírico, $\hat{X}_i$ es la predicción del modelo, $\epsilon \ll \bar{x}$ un factor de corrección para evitar valores nulos (que en general posee valores 2 ordenes de magnitud inferiores a la media del predictor) y $\delta = 10^{-18}$ suaviza el valor absoluto para garantizar la diferenciabilidad en la optimización.

Finalmente, para mitigar oscilaciones de alta frecuencia y garantizar que los parámetros epistemológicos varíen de forma suave y biológicamente plausible, se introdujo una penalización de suavidad temporal. Dada una

grilla de evaluación $\mathcal{T} = \{t_1, t_2, \dots, t_M\}$ se define

$$\mathcal{L}_{suave} = \frac{1}{M-1} \sum_{k=1}^{M-1} \|\text{NN}_{\theta}(t_{k+1}) - \text{NN}_{\theta}(t_k)\|_2^2 \quad (4)$$

que aproxima la minimización de la derivada temporal de las salidas de la red, forzando continuidades suaves en la estimación de los parámetros.

Por motivos experimentales durante las pruebas del modelo y a fin de facilitar y acelerar el aprendizaje de la red propuesta, se incorporó un entrenamiento secuencial acumulativo sobre la serie temporal (véase *Curriculum Learning*¹²). Esto quiere decir que se generaron ventanas de tiempo para el entrenamiento de la red neuronal, incrementando progresivamente la cantidad de datos utilizados para este proceso (todos estos fueron ordenados de forma secuencial y cronológica).

En las ventanas descritas se utilizaron tanto *Adam* como *L-BFGS* como algoritmos de optimización para minimizar la función de costo $\mathcal{L}_{total}$ en las proporciones indicadas en el cuadro 3. La elección de estos métodos se basa en la búsqueda de minimizar el tiempo de ejecución y obtener resultados con el mayor nivel de precisión posible; lo que es el resultado de la ejecución conjunta, primero Adam, luego L-BFGS, de estos algoritmos.

Fase de Entrenamiento	1	2	3	4	5	6	7	8	9
Ventana Temporal (t_{max})	20	40	80	150	250	350	500	700	T_{val}
Iteraciones ADAM	450	300	300	500	400	300	500	500	1200
Iteraciones L-BFGS	50	50	50	100	100	50	100	150	600
Iteraciones Acumuladas	500	850	1200	1800	2300	2650	3250	3900	5700

Cuadro 3: Esquema de entrenamiento híbrido por ventanas temporales (*Curriculum Learning*). Se combinan iteraciones del optimizador Adam seguidas por L-BFGS para refinar el ajuste en cada ventana temporal hasta alcanzar el tiempo total de observación (T_{val}).

3. Resultados

En función de los métodos de tratamiento y análisis de datos descritos anteriormente, se presentan y discuten los gráficos y resultados obtenidos para los datos utilizados. Los valores iniciales de los parámetros fueron los mostrados en el cuadro 1 y el cuadro 2 para todos los gráficos mostrados aquí.

En la figura 2 se puede observar la aproximación de las trayectorias predichas por el modelo para las variables monitoreadas realmente, a partir del entrenamiento, sobre los datos auténticos.




Figura 2: Representación de los ajustes dados por los parámetros encontrados para los casos confirmados en la figura 2a, muertes en la figura 2b y de vacunación mostrado en la figura 2c sobre los datos reales para dichas variables.

Para aquellas variables utilizadas que resultan constantes en el tiempo, se realizaron los gráficos de convergencia vistos en la figura 3. Sobre estas evoluciones a lo largo de las iteraciones se pueden contemplar valores finales de $\eta = 1,8 \times 10^{-5}$ días, $\omega = 20 \times 10^{-3}$ días y $T_R = 5,9$ días (véase que la diferencia entre el valor inicial T_0 y T_R es del 2,67 %).




Figura 3: Visualización de convergencia para los valores constantes en el tiempo predichos por el solucionador.

Mientras que para las variables con dependencia temporal se puede observar la figura 4, donde se aprecia

la evolución de las mismas a lo largo del período completo de trabajo en cada una de estas variables.




Figura 4: Visualización de los parámetros con dependencia temporal a lo largo de los días.

A partir de estos valores se puede calcular la solución a la ecuación diferencial (1), que tiene por solución la gráfica descrita en la figura 5, visualizando la evolución temporal de cada una de las variables de análisis, complementado con los gráficos previamente mencionados.




Figura 5: Representación de las trayectorias generadas por el modelo a partir de los parámetros ajustados.

La evolución de la función de costo total a lo largo de cada una de las iteraciones puede ser vista en la figura 6.




Figura 6: Evolución de la función de costo a lo largo de las iteraciones ejecutadas por *Curriculum Learning*

A partir de los ajustes mostrados antes, es posible visualizar los gráficos de residuos particulares de la figura 7




Figura 7: Representación de los residuos dados por los ajustes realizados casos confirmados en la figura 2a, muertes en la figura 2b y de vacunación mostrado en la figura 2c sobre los datos reales para dichas variables.

4. Discusión y conclusiones

Finalizado el procedimiento experimental expuesto anteriormente, se da por concluido el aporte de este trabajo. Se considera que, sobre los primeros 7000 días el modelo es altamente eficaz para seguir y describir la dinámica y el comportamiento poblacional de los datos. Más allá de esa fecha, se puede observar una pérdida en la buena estimación de las trayectorias, en particular, para los casos confirmados. Esto se puede observar tanto en el gráfico de ajuste como en los residuos del mismo donde se ve aún divergencia en la aproximación [X]. El comportamiento observado puede responder a las limitaciones en las aproximaciones del modelo. El mayor defecto del mismo es la simplificación de dosis, efecto que se puede observar sobre los datos de vacunación, donde sobre los 700 días el modelo pierde buena parte de esa calidad descriptiva. Los datos de primera dosis se estancan, pues las personas que querían (o debían) aplicarse dicha vacuna ya lo habían hecho y los reportes de vacunación subsiguientes responderían a la segunda o tercera dosis. También pueden influenciar los valores predefinidos como cotas para los parámetros optimizados. Podría resultar de interés estimar gráficos para valores no constantes de

perdida de vacunación, que permitieran una fluctuación temporal, en particular creciente a los momentos descritos.

En general, descartando el tramo final mencionado, se puede generar una lectura positiva y consistente de la física del problema planteado. Sobre los valores estimados para E e I se ve un aumento del primero de estos grupos previo a un crecimiento en el numero de infectados. Esto responde correctamente a las estimaciones esperadas pues los expuestos son, en su mayoría, un subconjunto en el estado retardado respecto a t de los infectados a dicho tiempo. Esto quiere decir que es razonable inferir, previo a la visualización de gráficas y métricas semejantes, que el numero de infectados es proporcional (en particular por una constante mayor a 0) a los expuestos previos. El tiempo entre estas olas responde al valor T por cómo se construye el sistema diferencial. En función a ellos, es posible ver una estricta positividad correspondiente con las variables esperadas¹ lo cual, como se comenta más adelante, no fue trivial de incorporar en el entrenamiento.

El comportamiento de la función de costo, que parece no converger a 0, es debido en buena parte a $\mathcal{L}_{suave}$ que, para las regiones donde las frecuencias del sistema se presentan altas, dicha función crece por construcción. Por ello, es de esperar que el costo total no converja a 0. De cualquier manera se puede ver cómo los residuos entre los ajustes y los datos se mantienen reducidos al final del entrenamiento (tener en cuenta que los residuos, por cómo se constituye el sistema, son otra representación de la optimización de $\mathcal{L}_{total}$),

Conclusivamente, se pondera como correcto el modelado diferencial dado por el sistema de ecuaciones con retardo propuesto aquí con el fin de estimar la dinámica de contagio del COVID-19 y así poder parametrizar dicha interacción en términos físicos, capaces de ser analizados individualmente para conocer el desempeño como sociedad para la

Consideraciones para trabajos posteriores

Para las gráficas presentadas, se utilizó, como ya se comentó, un valor inicial de retardo $T_0 = 6,0$ que se percibió como acorde a las fuentes citadas. En la propuesta utilizada, dado cómo se presenta la relación funcional con τ , es costoso para el optimizador modificar ampliamente el valor inicial. La propuesta de utilizar $T(\tau) = \tau$ fue descartada, pues presentó fluctuaciones rápidas y poco precisas para la convergencia de la componente de retardo, que carecían en buena parte de sentido físico real, llegando a valores de hasta 10 días, lo cual resulta absurdo para la dinámica dado que representaría una media del tiempo de incubación fuera de valores reales concebidos para la misma. En el modelo actual se permite una flexibilidad en la estimación del mismo para facilitar el aprendizaje de los patrones dinámicos sin alterar fuertemente los valores teóricamente estimados. Se consideraría útil trabajar en una mejor forma de aproximar este valor, dando mayor estabilidad a la red sin forzar fuertemente un valor original o, en caso contrario, establecer un método para que, de forma precisa, sea posible hallar valores de retardo previo al análisis completo dado por las ecuaciones diferenciales y, una vez con él, fijar el mismo como constante en el sistema.

¹Se deja en claro que, en parte, se fuerza a la red a aprender dicha positividad por como se modelan las ecuaciones en el código pero no de forma estricta, en particular para los expuestos y recuperados.

La incorporación de datos reales de entrenamiento para la variable de vacunación fue incorporada tardíamente en el proceso de trabajo dado que se veían resultados deficientes que subestimaban la cantidad de vacunados, lo cual fue solucionado a partir del agregado de los mismos. Por motivos de simplicidad en el modelo, tiempos de ejecución y capacidad de la base de datos, se utilizaron, como también se mencionó, las vacunaciones por primera dosis exclusivamente. Esto generó, en general, una merma en la correlación entre los datos y la función de ajuste, explicada en parte por la utilización de pesos menores a 1, permitiendo una suerte flexibilidad en la búsqueda por estimar mejor los datos descartados de vacunaciones. De esta manera, se buscó simular la aplicación de una segunda dosis que no evita la pérdida de inmunidad en gran parte de los individuos ya vacunados, lo que aproximaría mejor la realidad. Existen multitud de enfoques posibles como la incorporación de nuevas variables al modelo (vacunados por más de una dosis o una discriminación por la cantidad de dosis en particular). Sobre esto existen trabajos ya realizados y podría ser de gran utilidad sumar estas aproximaciones, junto con nuevos datos, para entrenar la red en busca de no solo aproximar mejor las curvas reales, sino obtener mejores estimaciones en los parámetros que garantizarían mejoras en el análisis de utilidad de las medidas de vacunación tomadas.

La estimación inicial de las variables a aproximar resulta crucial para la calidad del análisis posterior; en particular se trabajó con la estimación inicial de E pues si esta comienza, por ejemplo, siendo nula, por construcción del sistema los infectados que utilizan el tiempo anterior para construirse instante a instante fallan pues no encuentran el pico previo o una cantidad basal de expuestos que "justifique" si se quiere las olas de infección. El resultado de malas estimaciones iniciales se ve en caídas por debajo de 0 para una o ambas variables o en comportamientos exactamente opuestos, oleadas de infectados que preceden oleadas de expuestos. Una solución viable a este fenómeno, que no requiera la prueba y error, o una no tan precisa estimación para el valor inicial, es que la condición inicial para la segunda magnitud sea entrenable.

El uso de *Fourier Features* y un término independiente $\mathcal{L}_{dC}$ para facilitar el aprendizaje de altas frecuencias en períodos de rebrotes o nuevas olas resultó clave para la buena aproximación de resultados óptimos en dichas franjas. Sin ello, la red busca mantener la dinámica de suavidad (teniendo o no un término para ello en la función total de pérdida) y no encuentra trayectorias con cambios lo suficientemente bruscos para ajustar los datos.

Limitaciones y aportes futuros

Se espera poder trabajar más en detalle y concluir un modelo que pueda representar fielmente la totalidad de los datos en todas las ventanas de trabajo. En la misma línea, se considera prudente utilizar modelos similares para predecir dinámicas de contagio en otros Estados dentro del país (o incluso para la totalidad de este) y verificar la fiabilidad del modelo. Este tipo de trabajos se estima que pueda seguir siendo ejecutado sobre las bases aquí presentadas entrenando otras redes neuronales para cada Estado, e incluso sería interesante conocer cómo interaccionan las poblaciones estatales y saber si simulaciones de este tipo, con términos de interacción, resultan útiles sobre los hechos reales.

Por insuficiencia de tiempo, a su vez, no fue posible incluir un análisis exhaustivo de incertidumbres que

resulta esencial para conocer con precisión las variables y parámetros estimados. En el repositorio de GitHub, citado en la sección posterior, se presenta un primer acercamiento a ello empleando *MC-MC*, aún en desarrollo. Actualmente se trabaja para asegurar que el código sea no solo completamente funcional, sino que además produzca resultados coherentes para las incertidumbres y dispersiones calculadas.

5. Agradecimientos

Deseamos extender agradecimientos a la Facultad de Ciencias Exactas y Naturales de la Universidad de Buenos Aires por el apoyo constante a los estudiantes y la integración de materias de interés formativo actual tanto a programas de grado como de posgrado. Así como también a Sapienza Facundo por el comprometimiento con la materia dictada y predisposición hacia la misma. Para el trabajo se han utilizado herramientas de inteligencia Artificial como lo son *Gemini (Google, Advanced/Gemini 1.5 Pro)*¹³ para asistir en la construcción del formato en *latex* y la revisión del texto, y GitHub Copilot¹⁴ para completar fragmentos de código repetitivos. De todos modos, los bloques de código, resultados, ecuaciones y conclusiones fueron verificados manualmente.

6. Datos y Software

Los datos utilizados en el presente trabajo pertenecen a *JHU CSSE COVID-19 Data*¹⁵ y se encuentran disponibles en <https://github.com/CSSEGISandData/COVID-19>. El código desarrollado para este proyecto está disponible en <https://github.com/SantiiiGesualdi/COVID-19-Transmission-Dynamics-in-the-US> bajo licencia GPL-3.0.

Este trabajo utilizó Julia¹⁶ v1.12.6 con, principalmente, los paquetes *DifferentialEquations.jl*,¹⁷ *Lux.jl*,¹⁸ *SciMLSensitivity.jl*,¹⁹ *Zygote.jl*,²⁰ *DataFrames.jl*²¹ y *Plots.jl*.²²

Referencias

- [1] C. Jessica E. Metcalf, Dylan H. Morris, and Sang Woo Park. Mathematical models to guide pandemic response. *Science*, 369(6502):368–369, 2020.
- [2] M.J. Keeling and P. Rohani. *Modeling Infectious Diseases in Humans and Animals*. Princeton University Press, 2008.
- [3] William Ogilvie Kermack and À. G. McKendrick. A contribution to the mathematical theory of epidemics. *Proceedings of The Royal Society A: Mathematical, Physical and Engineering Sciences*, 115:700–721, 1927.
- [4] Ottar N. Bjørnstad, Katriona Shea, Martin Krzywinski, and Naomi Altman. The seirs model for infectious disease dynamics. *Nature Methods*, 17(6):557–558, 06 2020.
- [5] Christopher Rackauckas, Yingbo Ma, Julius Martensen, Collin Warner, Kirill Zubov, Rohit Supekar, Dominic Skinner, and Ali Ramadhan. Universal differential equations for scientific machine learning. *arXiv preprint arXiv:2001.04385*, 2020.
- [6] Alejandro Danón, Andrés S. Mena, and Andrés Ramasco. Covid-19 a nivel local: Seir+ un modelo para proyectar escenarios epidemiológicos y demandas hacia el sistema sanitario. *Ensayos de Política Económica*, XV(3), 2021.
- [7] Matthew Alexander, Lynn Unruh, Alex Koval, and William Belanger. United states response to the covid-19 pandemic, january–november 2020. *Health Economics, Policy and Law*, 17(1):62–75, 2022.
- [8] David Widmann and Chris Rackauckas. DelaydiffEq: Generating delay differential equation solvers via recursive embedding of ordinary differential equation solvers. *arXiv preprint arXiv:2208.12879*, 2022.
- [9] Nicola Guglielmi, Elisa Iacomini, and Alex Viguerie. Delay differential equations for the spatially resolved simulation of epidemics with specific application to covid-19. *Mathematical methods in the applied sciences*, 45(8):4752–4771, may 2022.
- [10] Matthew Tancik, Pratul P. Srinivasan, Ben Mildenhall, Sara Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, Ravi Ramamoorthi, Jonathan T. Barron, and Ren Ng. Fourier features let networks learn high frequency functions in low dimensional domains, 2020.
- [11] U.S. Census Bureau. State population totals: 2020–2024, 2024. Accessed: 2026-06-22.
- [12] Yoshua Bengio, Jérôme Louradour, Ronan Collobert, and Jason Weston. Curriculum learning. In *Proceedings of the 26th Annual International Conference on Machine Learning (ICML)*, pages 41–48. ACM, 2009.
- [13] Google. Gemini, 2026. Modelo de lenguaje grande (LLM). Fecha de consulta: 30 de mayo de 2026.
- [14] GitHub. Github copilot, 2026. Asistente de programación basado en IA. Fecha de consulta: 30 de mayo de 2026.

- [15] Ensheng Dong, Hongru Du, and Lauren Gardner. An interactive web-based dashboard to track COVID-19 in real time. *The Lancet Infectious Diseases*, 20(5):533–534, 2020.
- [16] Jeff Bezanson, Alan Edelman, Stefan Karpinski, and Viral B Shah. Julia: A fresh approach to numerical computing. *SIAM Review*, 59(1):65–98, 2017.
- [17] Christopher Rackauckas and Qing Nie. Differentialequations.jl – a performant and feature-rich ecosystem for solving differential equations in julia. *The Journal of Open Research Software*, 5(1), 2017.
- [18] Avik Pal. Lux: Explicit Parameterization of Deep Neural Networks in Julia, April 2023. If you use this software, please cite it as below.
- [19] Christopher Rackauckas et al. ScimlSensitivity.jl: Automatic differentiation and adjoints for equation solvers, 2022.
- [20] Michael Innes. Don’t unroll adjoint: Differentiating ssa-form programs. *CoRR*, abs/1810.07951, 2018.
- [21] Bogumił Kamiński, Tom Short, and Jacob Quinn. DataFrames.jl: Flexible and fast tabular data in Julia. *Journal of Statistical Software*, 107(4):1–36, 2023.
- [22] Simon Christ, Daniel Schwabeneder, Christopher Rackauckas, Michael Krabbe Borregaard, and Thomas Breloff. Plots.jl – a user extendable plotting api for the julia programming language. *Journal of Open Source Software*, 11(1):7, 2023.